

课程作业

作业一至作业十

课程导言 / 回归 / 分类 / 聚类 / 关联规则 / Python 实验

课程内容

围绕数据挖掘主要方法和 Python 实践展开。

商务数据挖掘全流程图

从业务问题到模型解释，再到管理决策的闭环



反馈迭代：新结果会改变数据采集、特征设计和模型选择

目录

01 第一次作业-课程导言

03 第三次作业-分类

05 第五次作业-关联规则

07 第七次作业-多元线性回归python

09 第九次作业-决策树python

02 第二次作业-回归

04 第四次作业-聚类

06 第六次作业-一元线性回归python

08 第八次作业-KNN python

10 第十次作业-聚类kmeans-HC python

第一次作业：课程导言

数据挖掘与机器学习的课程认知

作业主题

建立课程整体框架，理解数据挖掘在商务决策中的定位。

整理方法

以知识地图和流程图梳理课程逻辑。

本章内容

形成概念关系、课程路径、业务应用和学习小结。

知识框架

对应作业要求

阅读《参考教材1》的第1-2章、4-5章。

- 数据挖掘从业务问题出发，经过数据处理和算法建模，最后回到管理决策。
- 机器学习、神经网络和深度学习都可以看作从数据中学习规律的方法。
- 商务数据管理课程更关注模型结果在经营分析中的解释和使用。

现象

业务中可观察的变化，例如销售波动、客户流失、风险上升。

数据

用表格、日志、文本、图像等形式记录现象的证据。

算法

从数据中抽取规律的工具，包括回归、分类、聚类、关联规则。

决策

根据模型结果进行预测、分群、推荐和策略调整。

对应作业要求

阅读《白话机器学习算法》第1章，整理读书笔记。

课程知识结构地图



分析流程与应用场景

对应作业要求

整理本章上页PPT“本章概念汇总”，形成笔记。

1 提出业务问题

2 整理数据资产

3 选择分析任务

4 训练与评估模型

5 解释并形成行动

客户运营

识别高价值客户、流失风险客户和潜在转化客户。

商品管理

预测销量、发现组合购买关系、优化陈列和促销。

组织管理

用数据解释绩效差异、工作负荷和资源配置问题。

- 本页对应方法步骤整理，并补充常见商务应用。
- 完成内容按问题、方法、结果和结论展开。

对应作业要求

整理本章上页PPT“本章概念汇总”，形成笔记。

商务数据挖掘全流程图

从业务问题到模型解释，再到管理决策的闭环



反馈迭代：新结果会改变数据采集、特征设计和模型选择

方法整理与小结

对应作业要求

整理本章上页PPT“本章概念汇总”，形成笔记。

World → Data → Algorithm → Insight → Decision

适用数据

课程整体认知和学习规划。

注意事项

变量选择、阈值设置和数据处理方式都会影响结果。

整理重点

写清楚算法含义、使用步骤和结果说明。

- 课程导言帮助我先建立数据挖掘的整体认识。
- 做数据分析时，需要依次说明问题、数据、方法、结果和结论。
- 后续作业将在这个框架下学习回归、分类、聚类、关联规则和 Python 实验。

第二次作业：回归

用变量关系解释和预测连续结果

作业主题

理解回归分析如何描述变量关系，并用于预测。

整理方法

一元线性回归、多元线性回归、模型评价与残差诊断。

本章内容

形成模型公式、估计流程、案例解释和评价指标。

知识框架

对应作业要求

整理数据回归方法的基本方法、步骤。

- 回归用于处理连续型因变量，例如销售额、成绩、收入或利润。
- 模型系数既有数学含义，也需要业务解释。
- 评估回归不能只看拟合线，还要看误差、残差和使用场景。

因变量 Y

需要解释或预测的结果变量，例如利润、成绩、需求量。

自变量 X

影响结果的解释变量，可以是单个变量也可以是多个变量。

系数 β

衡量自变量变化对因变量的边际影响。


残差 ϵ

真实值与预测值之间的差异，用于诊断模型缺陷。

对应作业要求

整理一元线性回归和多元线性回归的基本数学模型。


回归分析：拟合、残差与评价



模型评价指标

R²	MSE	Residual
解释方差比例	平均平方误差	观测值 - 预测值

残差诊断示意



分析流程与应用场景

对应作业要求 整理Logistic回归的基本数学模型，理解其特点及与普通回归的区别。

1 收集 X 与 Y

2 绘制散点观察

3 估计模型系数

4 计算评价指标

5 解释与预测

学习时间预测成绩

一元线性回归可展示单个因素与结果的基本线性趋势。

投入预测利润

多元回归能同时考虑研发、管理、营销等因素。

工资与零售额


通过宏观变量关系解释消费规模变化。

- 本页对应方法步骤整理，并补充常见商务应用。
- 完成内容按问题、方法、结果和结论展开。

对应作业要求

阅读《白话机器学习》第六章“回归”，完成读书笔记。

多因素经营结果解释图



业务解释：模型不仅回答“能不能预测”，还帮助比较哪些因素对利润或绩效更关键。

方法整理与小结

对应作业要求

阅读《白话机器学习》第六章“回归”，完成读书笔记。

$$Y = \beta_0 + \beta_1 X + \varepsilon$$
$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

适用数据

连续型因变量和解释变量。

注意事项

变量选择、阈值设置和数据处理方式都会影响结果。

整理重点

写清楚算法含义、使用步骤和结果说明。

- 回归分析可以把变量之间的相关关系表示为模型。
- 一元回归便于理解基本思想，多元回归更接近真实业务场景。
- 模型结果需要结合评价指标和实际含义一起判断。

第三次作业：分类

从已标注样本学习类别预测规则

作业主题

理解分类任务、训练集测试集、分类器和评价指标。

整理方法

KNN、决策树、Logistic 等分类方法对比。

本章内容

形成分类流程、算法思想、边界图和评价解释。

知识框架

对应作业要求

整理分类算法的基本逻辑和几个基本概念。

- 分类是有监督学习，样本有明确类别标签。
- 分类器本质上是把特征空间划分为不同类别区域。
- 模型评价要关注错误类型，尤其是业务代价较高的错判。

训练集

用于学习模型规律的已标注样本。

测试集

用于检验模型在未知样本上的表现。

分类器

将输入特征映射到类别标签的模型。


混淆矩阵

展示预测正确和预测错误的分布。

对应作业要求

整理KNN算法的思想与算法步骤。

分类模型：边界、邻居与错误类型



KNN: 邻居投票



混淆矩阵

TP 84	FP 9
FN 13	TN 94

分析流程与应用场景

对应作业要求

阅读《白话机器学习》第七章KNN、第九章决策树，完成读书笔记。

1 获取标注数据

2 提取特征和标签

3 划分训练测试

4 训练分类器

5 评价错误类型

用户是否购买

根据年龄、收入等特征判断购买概率或类别。

客户是否流失

根据使用频率、消费变化和投诉记录预测流失风险。

风险是否异常


根据行为特征识别欺诈、违约或异常交易。

- 本页对应方法步骤整理，并补充常见商务应用。
- 完成内容按问题、方法、结果和结论展开。

对应作业要求

了解朴素Bayes、神经网络、决策树等算法思想。

决策树规则路径示意



可解释性：每条从根节点到叶节点的路径，都是一条可复述的业务规则。

方法整理与小结

对应作业要求

了解朴素Bayes、神经网络、决策树等算法思想。

KNN: 预测类别 = 最近 K 个邻居的多数类别
Decision Tree: 按特征阈值逐层分裂

适用数据

带类别标签的训练样本。

注意事项

变量选择、阈值设置和数据处理方式都会影响结果。

整理重点

写清楚算法含义、使用步骤和结果说明。

- 分类任务的关键标志是数据有标签。
- KNN 强调距离与投票，决策树强调规则和可解释路径。
- 分类评价应结合准确率、召回率、混淆矩阵和业务代价。

第四次作业：聚类

在无标签数据中发现群体结构

作业主题

理解无监督学习中“相似对象聚在一起”的思想。

整理方法

距离度量、K-means、层次聚类和可视化解释。

本章内容

形成聚类概念、算法流程、距离解释和应用场景。

知识框架

对应作业要求

整理聚类的概念。

- 聚类没有预设标签，主要用于发现数据内部结构。
- 聚类结果受特征选择、距离定义和算法假设影响。
- 聚类之后还需要根据样本特征解释每一类的含义。

簇

由相似对象组成的群体，是聚类的基本输出。

欧氏距离

衡量空间位置接近程度，适合数值型特征。

余弦相似度

衡量向量方向相似程度，常用于文本和高维数据。


可视化

用散点、树状图或降维图解释簇结构。

对应作业要求


整理类度量的两种基本方法：欧式距离和余弦定理。

聚类：从空间分布到簇结构



K-means: 中心与簇

层次聚类树状图



分析流程与应用场景

对应作业要求

整理K-means算法的原理和步骤。

1 选择特征

2 标准化处理

3 计算距离

4 运行聚类

5 命名和解释簇

客户分群

将用户划分为高价值、价格敏感、沉睡等群体。

商品分组

根据销量、价格、利润和品类属性形成经营组合。

文本主题

根据内容相似度发现新闻、论文或评论主题。

- 本页对应方法步骤整理，并补充常见商务应用。
- 完成内容按问题、方法、结果和结论展开。

对应作业要求

整理HC算法的过程。

课程知识结构地图



方法整理与小结

对应作业要求

掌握PPT中HC聚类结果图的含义。

K-means: 最小化簇内平方和
Hierarchical: 根据距离逐步合并形成树状结构

适用数据

无标签样本和连续/距离型特征。

注意事项

变量选择、阈值设置和数据处理方式都会影响结果。

整理重点

写清楚算法含义、使用步骤和结果说明。

- 聚类强调探索，不存在唯一标准答案。
- 距离度量会影响样本之间相似性的判断。
- 聚类输出需要结合样本特征进行命名和解释。

第五次作业：关联规则

用 Apriori 发现项与项的共现模式

作业主题

理解购物篮分析和强关联规则的筛选逻辑。

整理方法

项集、事务、支持度、置信度、Apriori 剪枝。

本章内容

形成规则指标、算法步骤、网络图和应用解释。

知识框架

对应作业要求

整理实体：有关联规则的背景知识。

- 关联规则关注项目共同出现的现象。
- 强规则需要同时满足支持度和置信度阈值。
- Apriori 利用频繁项集性质减少候选组合搜索量。

项

一个商品、症状、行业或行为标签。

事务

一次购买、一条病例或一条共同出现记录。

支持度


项集在全部事务中出现的比例。

置信度

A 出现时 B 也出现的条件概率。

对应作业要求 分析数据，理解课程提供学习案例的含义。

关联规则网络：购物篮中的共现关系



线越粗代表共同出现越频繁；规则 $A \Rightarrow B$ 还需要用支持度、置信度和提升度筛选。

分析流程与应用场景

对应作业要求 运行程序，参考后续文件包中的Python程序。

1 整理事务表

2 设定最小支持度

3 生成频繁项集

4 设定最小置信度

5 筛选强规则

购物篮

发现牛奶、面包、黄油等商品之间的共购模式。

菜单推荐

发现菜品组合偏好，辅助套餐设计。


医疗关联

探索疾病、症状、药物和基因之间的潜在关系。

- 本页对应方法步骤整理，并补充常见商务应用。
- 完成内容按问题、方法、结果和结论展开。

对应作业要求 分析结果，思考教材分析过程的含义。

Apriori: 频繁项集搜索层级



剪枝思想：若某项集不频繁，则包含它的更大项集也不可能频繁。

方法整理与小结

对应作业要求

分析结果，思考教材分析过程的含义。

$$\text{support}(A \Rightarrow B) = P(A \cap B)$$
$$\text{confidence}(A \Rightarrow B) = P(B|A)$$

适用数据

事务型数据和项目共现记录。

注意事项

变量选择、阈值设置和数据处理方式都会影响结果。

整理重点

写清楚算法含义、使用步骤和结果说明。

- 关联规则的重点是发现可解释的共同出现模式。
- 支持度保证规则不太罕见，置信度保证规则有条件可靠性。
- 规则最终是否有价值，取决于业务场景和行动可能性。

第六次作业：一元线性回归 Python

Student Scores 数据集建模实验

作业主题

用学习时间预测考试成绩。

整理方法

train_test_split + LinearRegression +
可视化拟合线。

本章内容

训练集、测试集拟合图和实验小结。

数据与实验目标

对应作业要求

读取数据并完成一元线性回归建模。

数据来源

Student Scores 数据集建模实验

建模目标

用学习时间预测考试成绩。

方法工具

train_test_split + LinearRegression + 可视化拟合线。

1 读取
studentscores.csv

2 提取 Hours 和
Scores

3 划分训练测试集

4 训练线性回归

5 预测并绘图

关键代码与步骤说明

对应作业要求

展示训练集和测试集拟合结果。

关键代码



```
dataset = pd.read_csv('studentscores.csv')
X = dataset.iloc[:, 0:1].values
Y = dataset.iloc[:, 1].values
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2)
regressor = LinearRegression()
regressor.fit(X_train, Y_train)
y_pred = regressor.predict(X_test)
```

- 本页摘录实验中直接使用的主要语句
- 代码顺序对应数据读取、特征提取、模型训练和结果预测。
- 后续页面结合图表说明运行结果。

结果图与模型输出

对应作业要求

说明模型输出含义。



结果解释与业务含义

对应作业要求 说明模型输出含义。

主要结果

学习时间和成绩整体呈正相关。

判断依据

训练集与测试集拟合图用于检查模型是否具备泛化能力。

补充说明

一元模型直观，但无法解释其他学习因素。

- 实验结果需要结合数据背景进行说明。
- 根据图表观察模型结果是否符合本次实验目标。

实验小结

对应作业要求

说明模型输出含义。

- 学习时间和成绩整体呈正相关。
- 训练集与测试集拟合图用于检查模型是否具备泛化能力。
- 一元模型直观，但无法解释其他学习因素。

通过本次实验，熟悉了从读取数据到解释结果的基本过程。

第七次作业：多元线性回归 Python

50_Startups 企业利润预测实验

作业主题

用多个经营投入变量预测企业利润。

整理方法

类别变量编码 + 多元线性回归 + 预测对比。

本章内容

变量关系散点图、预测结果和实验小结。

数据与实验目标

对应作业要求 读取50_Startups数据。

数据来源 50_Startups 企业利润预测实验	建模目标 用多个经营投入变量预测企业利润。	方法工具 类别变量编码 + 多元线性回归 + 预测对比。
---	-------------------------------------	--

- 1 读取 50_Startups
- 2 提取投入变量
- 3 编码 State
- 4 训练多元回归
- 5 比较预测结果

关键代码与步骤说明

对应作业要求

完成多元线性回归建模。

关键代码





```
X = dataset.iloc[:, 0:4].values
Y = dataset.iloc[:, 4].values
ct = ColumnTransformer(transformers=[('encoder', OneHotEncoder(), [3])])
X = np.array(ct.fit_transform(X))
regressor = LinearRegression()
regressor.fit(X_train, y_train)
y_pred = regressor.predict(X_test)
```

- 本页摘录实验中直接使用的主要语句。
- 代码顺序对应数据读取、特征提取、模型训练和结果预测。
- 后续页面结合图表说明运行结果。

结果图与模型输出

对应作业要求

对预测结果进行说明。



- 上方图表展示了数据分布、变量关系和模型输出。
- 通过对比不同图表，可以观察模型结果是否符合数据特征。

结果解释与业务含义

对应作业要求

对预测结果进行说明。

主要结果

多元回归能同时考虑多个影响因素。

判断依据

类别变量需要编码后才能进入数值模型。

补充说明

企业利润解释应结合系数和经营逻辑。

- 实验结果需要结合数据背景进行说明。
- 根据图表观察模型结果是否符合本次实验目标。

实验小结

对应作业要求

对预测结果进行说明。

- 多元回归能同时考虑多个影响因素。
- 类别变量需要编码后才能进入数值模型。
- 企业利润解释应结合系数和经营逻辑。

通过本次实验，熟悉了从读取数据到解释结果的基本过程。

第八次作业：KNN Python

Social Network Ads 购买预测实验

作业主题

根据年龄和估计收入预测是否购买。

整理方法

StandardScaler +
KNeighborsClassifier。

本章内容

样本分布图、KNN 代码和分类解释。

数据与实验目标

对应作业要求

读取Social Network Ads数据。

数据来源 Social Network Ads 购买预测实验	建模目标 根据年龄和估计收入预测是否购买。	方法工具 StandardScaler + KNeighborsClassifier。
--	---	---

- 1

读取广告数据
- 2

提取 Age/Salary
- 3

划分训练测试
- 4

特征标准化
- 5

KNN 投票分类

关键代码与步骤说明

对应作业要求

完成KNN分类实验。

关键代码


```
X = dataset.iloc[:, [2, 3]].values
y = dataset.iloc[:, 4].values
X_train, X_test, y_train, y_test = train_test_split(X, y)
sc = StandardScaler()
X_train = sc.fit_transform(X_train)
classifier = KNeighborsClassifier(n_neighbors=5)
classifier.fit(X_train, y_train)
```

- 本页摘录实验中直接使用的主要语句。
- 代码顺序对应数据读取、特征提取、模型训练和结果预测。
- 后续页面结合图表说明运行结果。



结果图与模型输出

对应作业要求

解释购买预测结果。



分类模型：边界、邻居与错误类型



结果解释与业务含义

对应作业要求

解释购买预测结果。

主要结果

KNN 思想直观，但对 K 值和特征缩放敏感。

判断依据

年龄和收入的空间分布可解释购买群体差异。

补充说明

分类结果应结合混淆矩阵检查错误类型。

- 实验结果需要结合数据背景进行说明。
- 根据图表观察模型结果是否符合本次实验目标。

实验小结

对应作业要求

解释购买预测结果。

- KNN 思想直观，但对 K 值和特征缩放敏感。
- 年龄和收入的空间分布可解释购买群体差异。
- 分类结果应结合混淆矩阵检查错误类型。

通过本次实验，熟悉了从读取数据到解释结果的基本过程。

第九次作业：决策树 Python

Social Network Ads 决策树分类实验

作业主题

用规则路径预测用户是否购买。

整理方法

DecisionTreeClassifier + 混淆矩阵。

本章内容

决策树规则、关键代码和实验小结。

数据与实验目标

对应作业要求

读取Social Network Ads数据。

数据来源 Social Network Ads 决策树分类实验	建模目标 用规则路径预测用户是否购买。	方法工具 DecisionTreeClassifier + 混淆矩阵。
---	---	---

- 1

读取数据
- 2

提取特征标签
- 3

划分训练测试
- 4

训练决策树
- 5

生成预测和混淆矩阵

关键代码与步骤说明

对应作业要求

完成决策树分类实验。

关键代码

```
classifier = DecisionTreeClassifier(criterion='entropy', random_state=0)
classifier.fit(X_train, y_train)
y_pred = classifier.predict(X_test)
cm = confusion_matrix(y_test, y_pred)
# 可进一步绘制树结构和决策边界
```


- 本页摘录实验中直接使用的主要语句。
- 代码顺序对应数据读取、特征提取、模型训练和结果预测。
- 后续页面结合图表说明运行结果。

结果图与模型输出

对应作业要求

说明决策树规则含义。

决策树规则路径示意



可解释性：每条从根节点到叶节点的路径，都是一条可复述的业务规则。

结果解释与业务含义

对应作业要求 说明决策树规则含义。

主要结果

决策树把分类过程表示成一条条判断规则。

判断依据

购买预测中，年龄和收入阈值可以帮助区分不同用户。

补充说明

树过深时容易只适应训练数据，需要适当控制复杂度。

- 实验结果需要结合数据背景进行说明。
- 根据图表观察模型结果是否符合本次实验目标。

实验小结

对应作业要求

说明决策树规则含义。

- 决策树把分类过程表示成一条条判断规则。
- 购买预测中，年龄和收入阈值可以帮助区分不同用户。
- 树过深时容易只适应训练数据，需要适当控制复杂度。

通过本次实验，熟悉了从读取数据到解释结果的基本过程。

第十次作业：聚类 KMeans-HC Python

Iris 数据集 K-means 与层次聚类

作业主题

在无监督条件下把 Iris 样本划分为 3 个簇。

整理方法

KMeans + linkage/fcluster + 聚类可视化。

本章内容

K-means 图、层次聚类树状图和实验小结。

数据与实验目标

对应作业要求

加载Iris数据集。

数据来源

Iris 数据集 K-means 与层次聚类

建模目标

在无监督条件下把 Iris 样本划分为 3 个簇。

方法工具

KMeans + linkage/fcluster + 聚类可视化。

1 加载 Iris

2 提取特征

3 运行 KMeans

4 运行层次聚类

5 可视化对比

关键代码与步骤说明

对应作业要求

完成K-means聚类 and 层次聚类。


关键代码

```
iris = load_iris()
X = iris.data
kmeans = KMeans(n_clusters=3, random_state=0)
y_kmeans = kmeans.fit_predict(X)
Z = linkage(X, method='ward')
clusters = fcluster(Z, t=3, criterion='maxclust')
```

- 本页摘录实验中直接使用的主要语句。
- 代码顺序对应数据读取、特征提取、模型训练和结果预测。
- 后续页面结合图表说明运行结果。

结果图与模型输出

对应作业要求 比较两类聚类结果。



- 上方图表展示了数据分布、变量关系和模型输出。
- 通过对比不同图表，可以观察模型结果是否符合数据特征。

结果解释与业务含义

对应作业要求 比较两类聚类结果。

主要结果

K-means 适合中心式划分，需要预先设定 K。

判断依据

层次聚类能通过树状图展示样本合并过程。

补充说明

聚类结果应结合可视化和专业背景解释。

- 实验结果需要结合数据背景进行说明。
- 根据图表观察模型结果是否符合本次实验目标。

实验小结

对应作业要求

比较两类聚类结果。

- K-means 适合中心式划分，需要预先设定 K。
- 层次聚类能通过树状图展示样本合并过程。
- 聚类结果应结合可视化和专业背景解释。

通过本次实验，熟悉了从读取数据到解释结果的基本过程。