

白话机器学习算法

信管2302 任宇轩 第一次作业

Contents

目录

白话机器学习算法第1章核心概念体系化梳理，涵盖数据科学基础、数据类型、预处理流程、机器学习范式及模型评估方法。

01 数据科学概述

02 数据基础概念

03 数据预处理流程

04 机器学习算法分类

05 模型评估与验证

06 本章概念汇总

数据科学概述：为何需要数据科学

数据科学是分析和利用数据的综合性学科，其核心价值在于克服人类判断力的局限性。通过整合多源信息、运用机器学习算法，数据科学能够从大型数据集中发现隐藏趋势、计算结果概率并快速获取准确结果。

学科定义：数据科学是涵盖机器学习、统计学和数学分支的综合性学科，其中机器学习是驱动模式识别和预测技术的主动动力。

人类局限：人类判断力受限于有限的主观经验和不完备的知识，容易导致误诊等决策失误，如书中提到的心脏病误诊案例。

技术优势：数据科学技术不依赖个人判断力，能够利用多数据源信息发现隐藏趋势、做预测、计算概率并快速获取准确结果。

大数据：大数据（Big Data）是数据科学的基础，指规模巨大、类型多样、处理速度快的数据集合，需要专门的技术和算法进行处理。

数据挖掘：数据挖掘（Data Mining）是从大量数据中发现模式和知识的过程，是连接原始数据与可执行洞察的关键技术。

数据基础： 变量类型与数据结构

变量类型

二值变量

最简单的变量类型，只有两种可能值，如"是否买鱼"的是或否

分类变量

可取两个以上值的离散类别，如顾客类别（企鹅、熊、兔子、马等）

整型变量

用整数描述数量信息，如水果购买量（1、4、6等具体整数）

连续变量

最精细的变量，用小数表示精确数值，如支出金额（5.30美元、9.70美元等）

数据结构

结构化数据

以表格形式组织，每行是观测点，每列是变量，如交易数据集

半结构化数据

具有一定结构但不严格遵循表格模式，如JSON、XML格式

非结构化数据

无预定义格式，如文本、图像、音频、视频等复杂数据

核心洞察： 数据科学中变量主要分为二值、分类、整型和连续四种类型，正确区分它们对选择合适算法至关重要。同时，数据按结构可分为结构化、半结构化和非结构化，其中表格形式的结构化数据是最常用的分析格式。

数据预处理：清洗、转换与特征工程

数据预处理是数据科学四步骤的第一步，包括变量选择、特征工程、缺失值处理和数据标准化。通过降维技术（如PCA）可以提取最有用信息获得精简变量集；数据标准化将变量统一到标准尺度（类似百分位数），消除度量单位差异，使不同变量可比。

变量处理与特征工程

- ✓ 变量选择：从众多变量中筛选与研究目标密切相关的变量，避免过多变量导致计算变慢或错误预测
- ✓ 特征工程：对单个变量重新编码（如将动物分为食草/食肉/杂食）或合并多个变量创造新特征
- ✓ 衍生变量：通过计算或转换原始变量得到的新变量（Derived Variable），用于提升模型预测能力


缺失数据处理与标准化

- ✓ 缺失数据处理：可用众数（分类/二值）或中位数（整型/连续）近似替换；或用监督学习算法计算；万不得已才移除
- ✓ 数据标准化：类似使用百分位数表示每个变量，将所有变量统一到标准尺度，消除单位差异
- ✓ 数据归一化：将数据按比例缩放至特定范围（如0-1），使不同量级特征可比，避免大数值特征主导

数据降维技术：PCA与t-SNE

核心原理：主成分分析（PCA）是一种降维技巧，通过找出数据散度最大的主成分（原始变量的加权组合），用较少变量描述数据。每个主成分都是原始变量的最优加权组合，如食物分析中可将脂肪、蛋白质、膳食纤维、维生素C四个变量降维为两个主成分（肉类vs蔬菜维度）。

- 01 主成分分析（PCA）：找出最能区分数据点的变量（主成分），数据点沿主成分维度最大限度分散，如用“维生素C-脂肪”组合同时区分蔬菜和肉类
- 02 PCA原理：主成分是原始变量的加权组合，权重可正可负，通过陡坡图确定合适的主成分数量，通常取曲线拐弯处的前几个成分
- 03 t-SNE：基于概率分布的降维技术，特别适用于高维数据可视化，能保持数据局部结构使相似样本在低维空间聚集
- 04 降维价值：减少计算复杂度、消除冗余信息、便于可视化（2D/3D展示）、提高模型泛化能力，但会损失部分信息且主成解释释性可能较差



主成分分析 PCA 数据降维示意图

机器学习算法分类：三大范式

机器学习按任务目标分为三大范式：无监督学习用于发现隐藏模式，监督学习基于已有模式做预测，强化学习则通过持续反馈自我改进。选择算法取决于任务类型——是探索结构、预测结果还是优化决策。

无监督学习 Unsupervised Learning 任务目标：发现数据中隐藏的模式，依靠算法从数据中发现未知结构 典型算法：k均值聚类、主成分分析、关联规则、社会网络分析 验证方式：通过间接手段验证，如检查分类是否符合已知类别	监督学习 Supervised Learning 任务目标：使用数据中已有的模式做预测，分为分类与回归两类任务 典型算法：回归分析、k最近邻、支持向量机、决策树、随机森林、神经网络 验证方式：直接评估，输入非训练数据对比预测结果与实际值	强化学习 Reinforcement Learning 任务目标：通过反馈结果不断改进预测，在探索和利用之间取得平衡 典型应用：多臂老虎机、广告投放优化、游戏AI、推荐系统 核心机制：根据反馈调整策略，epsilon递减策略逐步减少探索增加利用
--	---	---

参数调优：过拟合、欠拟合与正则化

参数调优是优化模型准确度的关键步骤。过拟合模型对随机波动过度敏感，泛化能力差；欠拟合模型过于简单，忽视基本模式。


过拟合 (Overfitting)：算法过度敏感，将数据中随机波动误认为持久模式，对当前数据预测准确度极高但对新数据预测能力差，泛化能力不强。

欠拟合 (Underfitting)：算法过于愚钝，忽视数据中的基本模式，导致对当前数据和未知数据的预测准确度均下降。

正则化 (Regularization)：通过引入惩罚参数人为增大预测误差，对模型复杂度增加进行惩罚，使算法在识别主要趋势和忽视微小变化间找到平衡。

参数调优策略：使用交叉验证法测试不同参数组合，观察模型在训练集和验证集上的表现差异，选择泛化能力最佳的参数配置。

正则化通过引入惩罚参数对模型复杂度进行惩罚，在准确度和复杂度间取得平衡，是提高模型泛化能力的核心手段。



模型复杂度与误差关系示意图

模型评价与验证方法

模型评价通过指标比较预测准确度，不同指标定义和惩罚误差的方式各异。分类任务常用预测准确率和混淆矩阵，回归任务使用均方根误差，验证过程通过训练集/测试集分离或交叉验证评估模型对新数据的泛化能力。

分类评价指标

预测准确率

正确预测所占比例，简单直观但无法揭示误差类型。如90%准确率可能掩盖严重的假负例问题，需要结合其他指标综合评估。

混淆矩阵

揭示真正例、假正例、真负例、假负例的数量分布，帮助识别模型在特定类别上的缺陷，是分类模型诊断的核心工具。

假正例与假负例

不同错误类型代价不同。如地震预测中假负例（漏报）代价远高于假正例（误报），需根据场景选择优化目标。

回归评价与验证

均方根误差（RMSE）

常用回归指标，每个误差取平方后平均再开方。大误差被显著放大，对异常值极其敏感，适合需要严格控制大偏差的场景。

训练集与测试集

将数据集分为两部分，训练集用于生成模型，测试集用于评估对新数据的预测准确度，避免模型过度记忆训练数据。

交叉验证

将数据集分多组，轮流用其他组训练、留一组测试，重复直至每组都测试过，取平均值作为最终评估，提高结果稳定性。

本章概念汇总

本章构建了数据科学的完整基础框架：从数据准备到算法选择，再到参数调优和模型评价，形成了从原始数据到 actionable insights 的完整流程。

数据基础概念

大数据与数据挖掘：规模巨大、类型多样、处理速度快的数据集；从中发现模式和知识的过程

数据类型与结构：二值、分类、整型、连续四种变量；结构化（表格）、半结构化（JSON/XML）、非结构化（文本/图像）

数据预处理：数据清洗（处理异常值/重复值）、缺失值处理（近似/计算/移除）、特征工程（构建衍生变量）

数据转换与降维

标准化与归一化：用百分位数等方法统一变量尺度；按比例缩放到特定范围（如0-1）

PCA与t-SNE：通过原始变量线性组合找出数据散度最大的主成分；保持局部结构的非线性降维技术

衍生变量：通过计算或转换原始变量得到的新变量，用于增强模型预测能力

机器学习范式

监督与无监督学习：发现隐藏模式（聚类、关联规则、PCA）；基于已有模式预测（回归、分类）

强化学习与过拟合：通过反馈持续改进（多臂老虎机）；对训练数据过度敏感，泛化能力差

正则化与交叉验证：引入惩罚参数控制模型复杂度；多轮训练测试循环评估模型泛化能力

数据科学研究四步骤

准备数据 → 选择算法 → 参数调优 → 评价模型