



大数据挖掘读书笔记

数据科学研究的四个主要步骤

目录



01

准备数据



02

选择算法



03

参数调优



04

评价模型



05

小结



01 准备数据

数据质量差 → 分析结果差

数据格式与变量类型

☰ 数据格式解析

表格是最常用的数据表示形式。

- 行 (Row): 代表一个数据点 (观测结果)
- 列 (Column): 代表一个变量 (属性/特征/维度)

类型	说明	示例
二值变量	只有两种可能的值	是否买鱼
分类变量	两个以上的取值	顾客类别
整型变量	整数表示的信息	水果购买量
连续变量	可表示小数	支出金额

理解变量类型是数据预处理和选择分析模型的基础

变量选择与特征工程

变量选择 (Variable Selection)

核心目标：

从众多变量中筛选出与研究目标密切相关的关键变量，剔除冗余信息。

常用方法：

- 试错法：逐步引入或剔除变量进行验证
- 相关性分析：借助散点图、热力图研究变量间关系

特征工程 (Feature Engineering)

重新编码 (Recoding)：

将变量转换为更广义的分类（如将年龄分组），降低数据粒度，便于宏观分析。

降维 (Dimensionality Reduction)：

合并多个变量，提取最有用的信息，有效减少数据复杂度。（详见第3章）

通过科学的变量选择与特征工程，为后续建模与分析奠定坚实基础

缺失数据处理

方法	适用情况	具体做法
近似法	二值/分类变量 → 众数替换 整型/连续变量 → 中位数替换	使用统计特征值直接替换缺失值，快速补全数据。
计算法	对数据精度有更高要求的场景	利用监督学习算法（如回归、随机森林）基于其他特征估算缺失值。
移除法	万不得已的情况（如缺失值过多且无法有效估算）	直接删除含缺失值的整行数据。注意：可能造成样本偏差。

💡 核心原则：优先尝试估算补全，谨慎使用删除操作，避免数据偏差。

02

选择算法

SELECTION OF ALGORITHMS



无监督学习 vs 监督学习

无监督学习 (Unsupervised)

- 🕒 任务目标：找出数据中隐藏的模式与结构
- 🔗 代表算法：k均值聚类、主成分分析(PCA)、关联规则、社会网络分析
- 🔊 核心特点：无标签数据，依靠算法自行发现规律
- ✅ 验证方式：间接验证（如检查分类是否符合常识）

监督学习 (Supervised)

- 🕒 任务目标：使用已有模式对未知数据做预测
- 🔗 代表算法：回归分析、k最近邻、支持向量机、决策树、随机森林、神经网络
- 🔊 核心特点：基于已有的“输入-输出”标签数据进行训练
- ✅ 验证方式：直接对比预测结果与实际真实值（准确率/损失函数）
- 📁 主要问题：回归问题（预测数值）和分类问题（预测类别）

强化学习与注意事项

强化学习 (Reinforcement Learning)

任务目标：通过智能体与环境的交互做预测，并根据环境反馈不断改进策略。

核心特点：具备持续进化能力，即使在模型部署上线后，仍可通过实时反馈迭代优化。

应用示例：在广告投放中，比较两个广告的转化效果，逐步提高表现更优广告的展示频率。

算法选择注意事项

数据适应性：不同算法对数据的结构（如连续型、离散型）和分布特征的分析能力存在显著差异。

结果差异性：不同算法的建模逻辑不同，导致输出结果的可解释性、稳定性和准确率本质各异。

决策建议：需结合具体业务场景，参考附录中不同算法的详细特点进行综合评估与选择。



03

参数调优

参数选项 = 调节算法的设置

过拟合与欠拟合

问题类型	核心描述	后果影响
过拟合	算法过度敏感，把随机波动错误地当成长久模式	当前数据准确度极高，但对新数据泛化能力极差
欠拟合	算法过于迟钝，忽略了数据中的基本模式和规律	对当前数据和新数据的预测准确度都比较差

解决方案：正则化

- 引入惩罚参数
人为增大预测误差，限制模型复杂度
- 平衡复杂度与准确度
迫使算法在两者之间寻找最佳平衡点
- 提升泛化能力
保持模型简单，确保对未知数据的适应性

核心目标：通过正则化手段，让模型既“学得到”数据规律，又“不过度学习”噪声细节。

CHAPTER 04

评价模型

MODEL EVALUATION



分类与回归指标

分类任务指标 (Classification)



预测准确率 (Accuracy)

正确预测的样本占总样本的比例，衡量模型整体判断的正确性。



混淆矩阵 (Confusion Matrix)

揭示预测错误的具体类型（真正例TP、假负例FN、假正例FP、真负例TN），评估不同错误类型的代价。

回归任务指标 (Regression)



均方根误差 (RMSE)

计算每个预测误差的平方后取均值再开方。对异常值极其敏感，能对大误差进行更严厉的惩罚，反映模型预测值与真实值的偏差程度。

合适的评价指标是量化模型性能、指导模型优化的关键步骤

验证方法

数据集划分 (常规方法)



训练集 (Training Set)

用于生成模型参数，不断调整和优化模型。



测试集 (Test Set)

模拟新数据，评估模型在未知数据上的泛化能力。

交叉验证 (小数据集适用)

01. 分组：将完整数据集划分为若干个互斥的子集。
02. 轮训：每次用一组做测试集，其余所有组作为训练集。
03. 循环：重复上述过程，直到每组数据都被测试过一次。
04. 评估：计算所有评估结果的平均值作为最终准确度。



核心价值：通过不同的验证策略，确保模型不仅在训练数据上表现优异，更能在真实的未知数据上保持高可靠性。

小结



准备数据

处理缺失值
特征工程构建
关键变量选择



选择算法

根据任务类型
监督/无监督
强化学习选择



参数调优

模型性能优化
平衡过拟合
与欠拟合问题



评价模型

选取合适指标
进行交叉验证
确保模型泛化性

数据科学研究闭环：数据驱动 · 算法赋能 · 持续优化