

关联规则与Apriori算法

基于Apriori算法的量化选股实践分析

任宇轩

2026.4.9

目录





关联规则简介

介绍关联规则的基本概念、核心指标，以及经典的Apriori算法原理，为后续的股票数据应用提供理论基础。

关联规则方法，是实现知识图谱“关系发现”的重要工具。

什么是关联规则

挖掘数据项集间的潜在联系

1

定义

关联规则是反映一个事物与其他事物之间的相互依存性和关联性。如果两个或多个事物之间存在一定的关联关系，那么其中一个事物就能够通过其他事物进行预测。

2

应用场景

关联规则广泛应用于市场购物篮分析、金融风险识别、疾病诊断、Web访问模式挖掘等领域，用于发现隐藏在数据背后的规律。

3

核心思想

通过分析事务型数据（如购物记录、交易数据）中不同项集的出现频率，找出频繁同时出现的项集组合，并衡量其关联强度。

数据挖掘是指以某种方式分析数据源，从中发现一些潜在的有用的信息，所以数据挖掘又称作知识发现，而**关联规则挖掘**则是数据挖掘中的一个很重要的课题，**顾名思义**，它是从数据背后发现事物之间可能存在的**关联或者联系**。举个最简单的例子，比如通过调查商场里顾客买的东西发现，30%的顾客会同时购买床单和枕套，而购买

核心衡量指标 (教材p110, 其他概念不一一列出)

支持度、置信度与强关联规则

1 支持度(Support)

指项集A和B在事务数据集中同时出现的频率。公式为: $\text{Support}(A \rightarrow B) = P(A \cup B)$ 。支持度衡量规则在统计意义上的普遍性。

2 置信度 (Confidence)

指在包含项集A的事务中, 同时包含项集B的概率。公式为: $\text{Confidence}(A \rightarrow B) = P(B|A)$ 。置信度衡量规则的可靠性或强度。

$$\text{confidence}(X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X)} = P(Y|X)$$

3 强关联规则

$\text{support}(XY) \geq \text{min_sup}$ 且 $\text{confidence}(XY) \geq \text{min_conf}$, 称关联规则 XY 为强关联规则, 否则称XY为弱关联规则。

Apriori算法原理（教材p112）

1 核心思想

使用一种称为逐层搜索的迭代方法，通过 k -项集来探索 $(k+1)$ -项集。其核心是基于“频繁项集的所有非空子集也必须是频繁的”这一先验知识。

2 步骤一：找频繁项集

扫描数据集，统计所有单个项（1-项集）的支持度，生成满足最小支持度阈值的所有频繁1-项集 L_1 。

3 步骤二：连接与剪枝

连接：使用 L_k 与自己连接，产生候选 $(k+1)$ -项集的集合 C_{k+1} 。剪枝：删除 C_{k+1} 中所有 $(k-1)$ -子集不在 L_k 中的项集。

4 步骤三：迭代计算

基于剪枝后的候选集 C_{k+1} ，再次扫描数据集计算支持度，生成新的频繁项集 L_{k+1} 。重复此过程，直到无法找到新的频繁项集为止。

基于频繁项集先验知识的挖掘算法



关联选股背景

阐述为何可以将关联规则应用于股票市场，并梳理基本面选股中行业分析的重要性，为关联选股提供背景知识。

选股核心逻辑

从行业到公司的投资思路

01

选股第一看行业

行业的景气度、生命周期、政策导向等决定了行业内公司的整体表现上限。选择处于成长期或景气周期的行业，是投资成功的首要前提。

02

选股第二看公司

在确定的行业中，通过比较分析，挑选出商业模式优秀、竞争力强、治理结构完善、具备成长潜力的优质公司。

03

行业深度分析

对行业进行深度研究，识别出驱动行业发展的核心因素，并预判行业的未来发展趋势，是基本面投资的核心工作。

理财

股票

股票市场

A股（人民币普通股股票）

你是如何从两千多只股票中选出心仪的股票的呢？

圆桌收录

「A股牛市」是否已经到来？>

时间长了，每个人都可以对一支股票的走势都能说出一二，但是说到买卖，你又如何从两千多只股票中选出心仪的股票的呢？经常复牌所有股票，一般人吃不消，说说你的交易系统如何建立股票池？

后面有很多回答有分歧，在于是能赚钱的股票，还是心仪的股票，我原本的意思是指心仪的股票！

看到很多人的回复，似乎犯了一条常见错误：
只做自己熟悉的股票！

关联规则应用

寻找股票间的“行业联动”

01

股票间存在联动

股票价格并非完全独立，同一行业的股票、受相同宏观经济因素影响的不同行业股票，其价格走势往往存在正相关关系，即“齐涨共跌”现象。

02

视为购物篮分析

将每只股票视为一个商品，一段时间内的市场交易记录视为购物篮。关联规则可以帮助我们发现，哪些股票（商品）倾向于同时被市场“买入”（上涨）。

03

发现行业关联线索

通过挖掘频繁项集和强关联规则，可以发现哪些股票经常一同出现，这些股票背后可能隐藏着未被市场充分关注的行业联动或投资主题。

04

构建关联选股模型

基于关联规则，可以构建一种数据驱动的选股模型，作为传统基本面分析的有效补充，辅助投资决策。



数据准备与处理

第五章压缩包中的数据以及代码展示

数据来源与概览

```
[1]: import csv
import random

# 生成商品池（示例商品名称）
products = [
    "智能手机", "蓝牙耳机", "机械键盘", "智能手表", "平板电脑",
    "无线鼠标", "笔记本电脑", "显示器", "移动电源", "摄像头",
    "游戏手柄", "投影仪", "打印机", "路由器", "硬盘",
    "电动牙刷", "吹风机", "空气炸锅", "咖啡机", "吸尘器",
    "加湿器", "电风扇", "电饭煲", "微波炉", "烤箱"
]

# 生成数据行
data = []
for i in range(1, 101):
    selected = random.sample(products, 3) # 确保同一行三个不重复
    data.append([i, selected[0], selected[1], selected[2]])

# 写入CSV文件
with open('products.csv', 'w', newline='', encoding='utf-8-sig') as f:
    writer = csv.writer(f)
    writer.writerow(["序号", "商品1", "商品2", "商品3"])
    writer.writerows(data)

print("CSV文件已生成: products.csv")
```

CSV文件已生成: products.csv

A. 导入库与数据初始化

导入模块：使用了 csv 模块用于文件写入，random 模块用于随机抽样。
商品池定义：创建了一个包含25种商品的列表（如“智能手机”、“蓝牙耳机”、“笔记本电脑”等），模拟了数码和家电类的商品库。

B. 数据生成逻辑

循环次数：range(1, 101) 生成了100条记录（序号从1到100）。
随机抽样：使用 random.sample(products, 3) 从25种商品中随机抽取3种。
特点：sample 函数保证了同一行内的商品不会重复。
数据结构：每条数据是一个列表，包含序号和3个商品名称，最终存入 data 列表。


序号	商品1	商品2	商品3
1	微波炉	笔记本电脑	显示器
2	游戏手柄	智能手表	空气炸锅
3	微波炉	电风扇	智能手机
4	机械键盘	加湿器	咖啡机
5	蓝牙耳机	平板电脑	吹风机
6	电动牙刷	吸尘器	笔记本电脑
7	路由器	蓝牙耳机	加湿器
8	电动牙刷	投影仪	笔记本电脑
9	摄像头	微波炉	移动电源
10	电动牙刷	吹风机	投影仪
11	微波炉	投影仪	加湿器
12	智能手表	电饭煲	游戏手柄
13	吸尘器	打印机	电动牙刷
14	机械键盘	电风扇	路由器
15	吹风机	电饭煲	智能手表
16	投影仪	硬盘	空气炸锅
17	无线鼠标	路由器	吹风机
18	平板电脑	吸尘器	显示器
19	摄像头	平板电脑	智能手表
20	电饭煲	烤箱	吹风机
21	电动牙刷	吹风机	微波炉
22	吹风机	微波炉	智能手表
23	移动电源	机械键盘	吹风机
24	投影仪	机械键盘	路由器
25	智能手表	平板电脑	机械键盘

使用apriori构建商品知识图谱

	support	itemsets	length	count
25	0.02	[加湿器, 咖啡机]	2	2
26	0.02	[加湿器, 打印机]	2	2
27	0.02	[加湿器, 摄像头]	2	2
28	0.02	[智能手机, 加湿器]	2	2
29	0.03	[智能手表, 加湿器]	2	3
...	...	...	...	...
103	0.03	[笔记本电脑, 硬盘]	2	3
104	0.02	[硬盘, 蓝牙耳机]	2	2
105	0.02	[硬盘, 路由器]	2	2
106	0.04	[笔记本电脑, 路由器]	2	4
107	0.02	[蓝牙耳机, 路由器]	2	2

83 rows × 4 columns

保留出现过两次以上的2项集





Apriori算法实践

演示如何使用Python中的`mlxtend`库实现Apriori算法，并详细解释关键参数（支持度、置信度）的设置与作用。

Python实现算法

使用mlxtend库调用Apriori函数

1

2

3

导入库

导入必要的库，包括用于数据处理的`pandas`，
用于关联规则挖掘的
`mlxtend.frequent\_patterns`。

调用apriori函数

```
`frequent_itemsets = apriori(trans_df,  
min_support=0.02, use_colnames=True)`
```

参数说明

`min\_support` 设置最小支持度阈值，只有支持度大于此值的项集才会被保留。
`use\_colnames` 指定使用列名，而非索引作为输出项集的元素。



分析数据（行列关系）

该矩阵为股票行业关联事务矩阵（表 6-4），共包含 10 行（T1-T10）和 6 列（银行、券商、钢铁、能源、医药、化工）

分析数据（行列关系）

表 6-4 股票行业关联事务矩阵

	银行	券商	钢铁	能源	医药	化工
T1	1	1	0	0	1	0
T2	0	0	0	1	0	1
T3	1	1	1	0	0	0
T4	1	1	0	1	0	1
T5	0	0	1	0	1	0
T6	0	1	1	0	0	0
T7	1	0	1	0	0	0
T8	1	1	1	0	1	1
T9	1	1	1	0	0	0
T10	1	1	0	1	0	0

行（T1-T10）：代表 10 个独立的交易日 / 交易周期事务，每一行对应一个观测周期内的行业涨势情况。

列（银行、券商、钢铁、能源、医药、化工）：代表 6 个不同的行业类别，每一列对应一个行业的涨势判定结果。

单元格取值：1 表示该行业在对应交易日满足“涨势好”的标准（如 10 个交易日内涨幅超大盘 5%）；0 表示不满足该标准。

谢谢观看

