

简单线性回归模型

信管2302 任宇轩 第六次作业

内容概览

01	数据向量化	03
02	模型参数获取	08
03	模型评估指标	15
04	训练测试划分	22

数据向量化：X必须是列向量

在scikit-learn中，输入特征X必须是二维数组（ $N \times 1$ 矩阵），这是为了保证矩阵运算的维数一致性。

- 01 **数据框提取：**从数据框中提取X时使用`dataset.iloc[0:1].values`，确保得到的是 $N \times 1$ 的二维数组而非一维序列
- 02 **列向量形状：**列向量的形状 $(25, 1)$ 明确标识25个样本和1个特征，满足scikit-learn对输入维度的严格要求
- 03 **矩阵运算要求：**scikit-learn的`fit`方法内部使用矩阵运算，要求X必须是二维数组，一维数组会导致维度不匹配错误
- 04 **扩展性设计：**保持二维结构便于扩展到多变量回归，当增加特征时只需添加列而无需重构代码逻辑

计算：

$$1. \begin{bmatrix} 1 & 2 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 3 \\ -1 \end{bmatrix}; = \begin{bmatrix} 1 \\ 1 \end{bmatrix};$$

$$2. \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}. = \begin{bmatrix} 2x \\ y \end{bmatrix}.$$

$$\begin{bmatrix} 3 \\ -1 \end{bmatrix} \text{左乘矩阵} \begin{bmatrix} 1 & 2 \\ 0 & -1 \end{bmatrix} \text{后变成一个新的向量} \begin{bmatrix} 1 \\ 1 \end{bmatrix};$$

$$\begin{bmatrix} x \\ y \end{bmatrix} \text{左乘矩阵} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \text{后变成一个新的向量} \begin{bmatrix} 2x \\ y \end{bmatrix}.$$

"列向量的形状 $(N, 1)$ 明确区分了样本维度（行）和特征维度（列），这是进行矩阵乘法 $X\beta$ 和后续梯度计算的基础。"

列向量 vs 行向量：维度对比

在NumPy中， $(25, 1)$ 和 $(25,)$ 有着本质区别：前者是二维矩阵（列向量），后者是一维数组。scikit-learn严格要求X为二维矩阵，因为一维数组会被解释为单一序列而非特征矩阵，导致模型无法识别特征维度，进而引发维度不匹配错误或错误的计算结果。

正确的列向量

- ✓ 使用`X = dataset.iloc[:, 0:1].values`得到形状 $(25, 1)$ 的二维数组
- ✓ 明确区分样本维度（25行）和特征维度（1列），符合矩阵乘法要求
- ✓ scikit-learn可正确识别为单变量输入，模型训练正常进行

错误的行向量

- ✗ 使用`X = dataset.iloc[:, 0].values`会得到形状 $(25,)$ 的一维数组
- ✗ 丢失特征维度信息，scikit-learn无法确定特征数量
- ✗ 可能引发ValueError或导致错误的矩阵运算，产生无意义的模型参数

获取模型参数： b_0 与 b_1

训练后的LinearRegression对象通过`intercept_`和`coef_`属性存储模型参数，分别对应简单线性回归方程 $y = b_0 + b_1 \cdot x$ 中的截距项与斜率系数。


01 截距 b_0 : 通过 `regressor.intercept_` 获取，表示特征值为0时目标变量的基准预测值

02 斜率 b_1 : 通过 `regressor.coef_[0]` 获取，表示特征每增加一个单位时目标变量的变化量

03 熟模型应用: 训练后的模型对象可直接用于 `predict` 方法对新数据进行推断预测

04 最小二乘法: 参数估计基于最小二乘法原理，寻找使残差平方和最小的最优 b_0 和 b_1 组合

什么是线性回归

 $Y \sim X$ $Y = \Theta X$ 


简单线性回归: $y = b_0 + b_1 \cdot x$
截距 b_0 为y轴交点, 斜率 b_1 为直线倾斜程度

模型可视化：数据与拟合直线

Key Insight

通过matplotlib可视化原始数据散点、预测值和回归直线，可以直观验证模型的拟合质量。良好的拟合表现为回归线穿过数据云的中心区域，残差在直线两侧随机分布。


- 01 使用 `plt.scatter(X, Y, color='red')` 绘制原始数据散点，展示学习时长与分数的真实分布关系
- 02 使用 `plt.plot(X, regressor.predict(X), color='blue')` 绘制回归直线，直观呈现模型的预测趋势
- 03 通过对比红色真实点和预测点的位置，可以直观判断模型是否存在欠拟合或过拟合现象
- 04 可视化检查是模型评估的必要补充，能发现纯数值指标无法捕捉的异常模式（如非线性关系）



模型评价：R² 决定系数

R²（决定系数）取值范围0到1，衡量模型对目标变量变异的解释能力。**R² = 0.9529**表示模型能解释95.29%的目标变量变异，说明学习时长与分数之间存在强线性关系，模型拟合优度极高。

- 01 通过`regressor.score(X, Y)`计算R²，其数学本质是 $1 - \text{RSS}/\text{TSS}$ ，即模型解释方差占总方差的比例。
- 02 R²越接近1表示拟合效果越好，通常>0.8认为模型可用，>0.9表示拟合优度很高。
- 03 R² = 0.9529意味着学习时长可以解释分数95.29%的变化，剩余4.71%由其他因素或噪声导致。
- 04 注意R²高不代表模型无误，仍需检查残差分布和可视化结果，避免过度拟合或遗漏关键变量。



训练/测试集比例对R² 的影响

test_size=0.2（80%训练）是经验平衡点：训练数据充足保证模型充分学习数据模式，测试数据量（20%）足够大以提供统计显著的泛化能力评估。



防止过拟合： test_size=0.2表示80%样本用于训练模型参数，20%用于独立评估模型泛化能力。

统计可靠性： 在样本量25时，80/20划分提供20个训练样本和5个测试样本，确保基础评估可信度。

关键点与最佳实践

简单线性回归的成功实现依赖于四个技术细节的严格把控：正确的数据向量化确保维度一致性，准确的参数提取支撑模型解释，科学的 R^2 评估保证模型质量，合理的训练测试划分平衡拟合与泛化。掌握这些细节比单纯调用API更能体现数据科学的专业性。

数据准备

始终使用`X = dataset.iloc[:,0:1].values`保持二维结构，避免一维数组导致的维度错误

模型训练

通过`regressor.fit()`训练后，使用`intercept_`和`coef_`提取参数，理解其数学和业务含义

评估验证

$R^2 > 0.9$ 表示优秀拟合，但必须结合可视化检查残差分布，数值与图形双重验证

谢谢观看

掌握细节，构建可靠的预测模型