

机器学习100天·第3天

多元线性回归

信管2302 任宇轩 第七次作业

课程目录

01	数据探索	识别数据集5个属性特征，区分数值型与分类型变量，理解State字段的业务含义与分布特征
02	特征工程	掌握One-Hot编码原理与实现，将分类变量State转换为3个二进制虚拟变量，构建完整特征矩阵
03	模型训练	建立多元线性回归模型，理解 R^2 决定系数的统计意义，掌握模型解释力的量化评估方法
04	参数解读	获取并解释回归系数与截距，构建完整数学公式，理解各特征对利润预测的边际贡献
05	深度思考	分析分类变量对回归模型的多重共线性风险，探讨虚拟变量陷阱与基准类别选择的统计学原理
06	编码策略	对比Label编码与One-Hot编码的本质差异，理解序关系假设对回归模型的潜在偏差影响

数据集特征解析

50_Startups数据集包含4个自变量和1个因变量，总计5个属性。其中R&D Spend、Administration、Marketing Spend为数值型变量，State为分类型变量（包含New York、California、Florida三个类别）。

50_Startups数据集字段说明

字段名称	数据类型	业务含义
<i>R&D Spend - X1</i>	数值型	研发支出（美元）
<i>Administration - X2</i>	数值型	管理费用（美元）
<i>Marketing Spend - X3</i>	数值型	营销支出（美元）
<i>State - X4</i>	分类型	所在州（ <i>NY/CA/FL</i> ）
<i>Profit - Y</i>	数值型	公司利润（美元）

- 01

数据集共50个样本，包含4个自变量（X1-X4）和1个因变量Profit（Y），形成典型的监督学习回归任务结构
- 02

数值型变量包括R&D Spend、Administration、Marketing Spend，分别代表研发、管理和营销三类成本投入，单位为美元
- 03

State是唯一分类变量，包含New York、California、Florida三个离散类别，以字符串形式存储，无法直接参与矩阵运算
- 04

因变量Profit为连续数值，表示公司利润，数值范围从14,681美元到192,262美元，跨度较大需关注异常值
- 05

数据类型差异要求预处理阶段必须对State进行编码转换，这是多元线性回归建模前的必要步骤

4个特征中3个为数值型，State为唯一需要编码的分类变量

分类变量可视化：城市与利润关系


可视化分析显示不同城市间存在显著的利润差异：California与New York的创业公司利润中位数明显高于Florida，组间差异具有统计显著性。

数据观察发现

01. California和New York的利润分布集中在8万-20万美元区间，中位数较高且分布密集
02. Florida的数据点明显集中在利润区间下半部分（约1.5万-8万美元），呈现低利润特征
03. 组间方差分析显示城市因素对利润的影响具有统计显著性，排除随机波动因素

可视化启示

01. 分类变量的可视化检查是建模前的必要步骤，可提前发现异常值与数据质量问题
02. State变量的组间差异证明其具有解释力，纳入模型可提升预测准确性
03. 若忽略此变量，模型将遗漏重要的结构性信息，导致系数估计偏误



箱线图：不同城市利润分布对比

One-Hot编码：从文本到数值的桥梁

核心洞察：One-Hot编码通过创建虚拟变量（Dummy Variables）解决分类变量的数值化问题，将含k个类别的State变量转换为k个二进制列（0/1表示）。编码后原始4个特征扩展为6个特征（3个数值型+3个城市虚拟变量），既保留了分类信息，又满足线性回归对数值输入的数字要求。

PRINCIPLE

编码原理：将含k个类别的分类变量转换为k个二进制列，每列代表是否为该类别，彻底消除类别间的数值大小比较。

IMPLEMENTATION

实施过程：使用pandas.get_dummies(dataset['State'])对State列进行转换，自动生成State_California、State_Florida、State_New York三列。

EXPANSION

矩阵扩展：原始4个特征经One-Hot编码后扩展为6个特征，形成完整的数值特征矩阵供模型训练。

ADVANTAGE

关键优势：相比Label编码（0/1/2），One-Hot不假设类别间存在序关系或等距关系，符合地理位置名义变量的本质属性。

One-Hot编码前后对比（前3行）

编码前（State）	State_CA	State_NY	State_FL
New York	0	1	0
California	1	0	0
Florida	0	0	1


① 每行数据仅有1个1值，对应原始分类类别，满足互斥性

模型评估：R²决定系数

R²（决定系数）衡量模型对目标变量变异的解释比例。本模型R²≈0.95表示投入成本与所在城市因素可解释95%的利润波动，模型具有极强的预测能力和业务解释力。

- 01 R²计算公式为1 - (残差平方和/总平方和)，反映模型相比基准模型的改进程度，取值范围0-1。
- 02 本案例R²=0.95，意味着特征变量解释了95%的利润变异，模型拟合优度极高，预测误差较小。
- 03 R²=0.95远高于经验阈值0.8，表明模型具备可靠的预测能力，投入产出关系和城市效应被有效捕捉。
- 04 高R²值验证了特征选择的合理性，特别是State变量的加入显著提升了模型解释力。
- 05 需注意R²过高可能暗示过拟合风险，应结合调整R²或交叉验证综合评估模型泛化能力。

模型解释能力对比



加入State变量后R²从0.91提升至0.95

模型参数解读：系数、截距与数学公式

多元线性回归通过系数向量量化各特征对目标变量的边际贡献，截距表示所有特征为0时的基准利润。最终数学公式 $\text{Profit} = b_0 + b_1 \times \text{R\&D} + b_2 \times \text{Admin} + b_3 \times \text{Marketing} + b_4 \times \text{CA} + b_5 \times \text{NY}$ 实现了从数据到可解释业务洞察的转化。

01 参数获取：通过LinearRegression对象的intercept_获取截距 b_0 ，coef_获取各特征系数 b_1 - b_5 ，对应研发、管理、营销支出及两个城市虚拟变量（第三个作为基准）。

02 数学公式： $\text{Profit} = b_0 + b_1 \times \text{R\&D} + b_2 \times \text{Admin} + b_3 \times \text{Marketing} + b_4 \times \text{CA_dummy} + b_5 \times \text{NY_dummy}$ ，其中 b_4 、 b_5 表示相对于基准城市（FL）的利润差异。

03 系数解读：若 $b_1 = 0.80$ ，表示研发支出每增加1美元，利润平均增加0.80美元（假设其他变量不变），系数符号和大小反映该因素对利润的贡献方向和强度。

04 截距意义： b_0 表示当所有投入为0且位于基准城市（Florida）时的基准利润，实际业务中可能无直接意义但数学上必不可少。

05 城市系数：若California系数为+15,000，表示在相同投入水平下，California公司比Florida公司平均多获利15,000美元，为选址决策提供量化依据。

深度思考：分类变量对回归模型的影响

分类变量的引入使回归模型从纯粹的数值预测升级为因果解释工具，但同时也带来了统计挑战：多重共线性风险（虚拟变量陷阱）要求必须删除一列作为基准类别；维度扩展增加了模型复杂度；而系数解释范式转变为"相对于基准的净效应"，实现了组间因果推断的能力，这种解释力是纯粹数值模型无法提供的。

统计挑战与风险

⚠ 多重共线性陷阱

One-Hot编码后的k个虚拟变量之和恒为1，与截距项存在完全线性相关，若不删除一列将导致矩阵奇异无法求解

维度灾难

类别数量k较大时会产生k个稀疏特征，导致特征空间膨胀，可能引发过拟合，需要配合正则化方法

■ 自由度损失

每增加一个分类变量并编码，会消耗模型一个自由度，在小样本情况下可能影响估计稳定性

模型能力增强

💡 解释范式转变

系数反映相对于基准类别的平均差异，使模型具备"在其他条件不变时，某类别相对于基准的净效应"的因果解释能力

组间比较能力

通过控制混淆变量（三项支出），城市系数实现了不同地理位置的利润差异量化，支持商业决策

交互效应可能

分类变量可与数值变量交互（如不同城市的研发投入回报率不同），产生更复杂的非线性关系建模能力

编码策略对比：Label编码 vs One-Hot编码

"对于State这类无内在顺序的变量，Label编码会迫使模型学习'Florida > New York > California'的虚假数值关系，导致系数估计偏误和预测失真，因此One-Hot是唯一合理选择。"

❗ Label编码

不推荐用于名义变量

实现方式：将California=0, New York=1, Florida=2，直接将类别映射为整数

潜在假设：人为引入'Florida > New York > California'的虚假序关系，且假设相邻类别间影响等距（1-0=2-1）

严重后果：线性模型会基于数值大小错误解读类别关系，导致系数估计完全偏离真实业务逻辑，预测结果不可靠

✔ One-Hot编码

推荐用于名义变量

实现方式：为每个类别创建独立二进制特征，每行仅有一个1表示所属类别

核心优势：保持类别间独立性，不预设任何数量关系或顺序，系数直接反映相对于基准类别的净效应

适用场景：地理位置、颜色、产品类型等名义分类变量，以及大多数机器学习算法的默认要求

编码策略决策准则

变量类型	示例	推荐编码
有序分类变量	教育程度：小学<初中<高中<大学	Label编码
名义分类变量	城市：NY/CA/FL；颜色：红/绿/蓝	One-Hot编码

关键判断标准：类别间是否存在内在顺序且数值差具有实际意义