

机器学习100天——第25天：决策树 (Decision Tree)

第九章作业

•1 加入性别因素，看看acc的变化

```
# 将 Gender 转换为数值型
dataset['Gender'] = dataset['Gender'].map({'Male': 1, 'Female': 0})
```

```
# 选择特征: Gender, Age, EstimatedSalary
X = dataset[['Gender', 'Age', 'EstimatedSalary']].values
y = dataset['Purchased'].values
```

```
accuracy = (cm[0,0] + cm[1,1]) / cm.sum()
print("混淆矩阵: \n", cm)
print("准确率: ", accuracy)
```

```
混淆矩阵:
[[54  4]
 [ 1 21]]
准确率: 0.9375
```



结论：加入性别后准确率从 0.925 下降到 0.9375，说明在这个数据集中性别对购买行为的影响比其他因素要大

•2 如何不进行特征缩放，预测的准确性有什么变化？

4: 特征缩放

```
#from sklearn.preprocessing import StandardScaler  
#sc = StandardScaler()  
#X_train = sc.fit_transform(X_train)  
#X_test = sc.transform(X_test)
```

```
accuracy = (cm[0,0] + cm[1,1]) / cm.sum()  
print("混淆矩阵: \n", cm)  
print("准确率: ", accuracy)
```

混淆矩阵:

```
[[54  4]  
 [ 2 20]]
```

准确率: 0.925

结论：不进行特征缩放后准确率还是0.925，说明决策树/随机森林是基于分裂规则的，不受特征量纲影响

•3 比较KNN、Logistic、决策树在该数据集上的表现。

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score

# 训练 Logistic 回归 (标准化后的数据)
log_reg = LogisticRegression(random_state=0)
log_reg.fit(X_train, y_train)
y_pred_log = log_reg.predict(X_test)
acc_log = accuracy_score(y_test, y_pred_log)

# 训练 KNN (k=5, 标准化后的数据)
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)
y_pred_knn = knn.predict(X_test)
acc_knn = accuracy_score(y_test, y_pred_knn)

# 训练决策树 (不使用标准化, 也可用标准化后的数据, 结果一致)
tree_clf = DecisionTreeClassifier(criterion='entropy', random_state=0)
tree_clf.fit(X_train, y_train)
y_pred_tree = tree_clf.predict(X_test)
acc_tree = accuracy_score(y_test, y_pred_tree)

print(f"Logistic准确率: {acc_log}")
print(f"KNN准确率: {acc_knn}")
print(f"决策树准确率: {acc_tree}")
```

Logistic准确率: 0.925


KNN准确率: 0.8375

决策树准确率: 0.9125

结论: 这里来说Logistic的准确率更高, 但通常 KNN和随机森林表现较好, Logistic 略低。决策树容易过拟合, 若不加剪枝可能训练集准确率高但测试集稍低。

•4 把决策树输出看看长什么样

Decision Tree Structure (with Gender)



•**根节点**：根据 年龄 是否 ≤ 44.5 划分数据集。

左侧分支（年龄 ≤ 44.5 ）：样本以“未购买”为主（199 vs 121）。

进一步按 薪资（EstimatedSalary）划分：

若薪资 $\leq 30,500 \rightarrow$ 多数为“未购买”（184 vs 44），判定为 未购买。

若薪资 $> 30,500 \rightarrow$ 随后再按年龄 30.5 细分，低龄（ ≤ 30.5 ）几乎全为未购买（178 vs 8）。

右侧分支（年龄 > 44.5 ）：样本以“已购买”为主（25 vs 77）。

进一步按 薪资 $\leq 41,500$ 划分：

若薪资 $\leq 41,500 \rightarrow$ 已购买占优（14 vs 45），判定为 购买。

若薪资 $> 41,500 \rightarrow$ 后续再细分，但整体仍偏向购买。