

小组案例总结

第一章 项目背景

在当前的就业市场中，技术岗位的薪酬水平一直是求职者和招聘方共同关注的核心话题。无论是刚刚走出校门的应届毕业生，还是已经积累了一定经验的从业者，都希望对自己的市场价值有一个清晰的认识。然而，技术岗位的薪酬并不是一个简单的数字，而是受到多种因素综合作用的结果。岗位的具体类型，比如是软件工程师、数据分析师还是人工智能工程师，往往直接决定了薪酬的起步水平和大体范围。除此之外，工作经验年限、学历层次、掌握的技能数量、所处的行业赛道、所在公司的规模大小、工作所在的城市或地区，甚至是否允许远程办公，都会在薪酬的最终确定中扮演重要角色。

在传统的招聘场景中，薪酬的确定往往依赖于招聘人员的主观经验和对市场的个人判断。这种方式虽然有一定的参考价值，但难以做到全面、客观和精确。一个招聘经理可能对自己熟悉的领域有比较准确的感觉，但当面对跨行业、跨地区或者新兴技术岗位时，经验判断就可能出现偏差。求职者这一端更是如此，很多人只能通过零散的招聘信息或者社交网络上的分享来大致估算自己的薪资期望，缺乏系统性的数据支撑。

随着机器学习技术的快速发展，我们已经能够从大规模数据中自动发现隐藏的模式和规律。与人工判断相比，机器学习方法有几个明显的优势：首先，它可以在极短的时间内处理海量的历史招聘数据，这是人脑无法匹敌的信息处理能力；其次，机器学习的预测基于数据本身而非主观感受，因此更加客观；第三，通过特征重要性分析，我们还可以识别出哪些因素对薪资的影响最大，从而为求职者的职业规划提供有据可依的参考。

基于以上背景，本次小组案例实践选择了一个典型的机器学习应用场景——技术岗位薪酬预测与薪资区间识别。我们使用了一个包含二十五万条真实招聘记录的数据集，涵盖了岗位名称、工作经验、学历、技能数量、行业类型、公司规模、工作地区、远程办公方式等多个维度的信息。通过对这些数据的系统分析和建模，我们希望能够回答两个核心问题：第一，如何比较准确地预测一个技术岗位的具体薪资数值；第二，如何判断该岗位属于哪一个薪资档次，

比如是低薪、中薪还是高薪区间。

整个项目的实施过程覆盖了数据挖掘的完整工作流程，从最初的问题定义和目标明确，到数据的准备和预处理，再到数据的探索性分析和可视化，然后是多种机器学习模型的建立与训练，最后是模型的评估、比较和实际应用展望。每一个环节都是循序渐进、环环相扣的，前面阶段的工作质量直接影响后续建模的效果。这种系统性的实践经历，对于我们理解数据挖掘方法论的整体框架非常有帮助。

下面这张图展示的是数据集中所有技术岗位年薪的整体分布情况。从直方图的形状可以看出，大部分岗位的年薪集中在十到二十万之间，呈现出一个比较典型的右偏分布——薪资特别高的岗位虽然存在但数量较少，而薪资较低的岗位数量也相对有限。这种分布形态为我们后续的薪资格局分析提供了直观的起点。




图 1-1 薪资分布直方图

第二章 项目目的

在明确了项目背景之后，我们需要清晰地界定这次实践的两个核心目标。从机器学习的任务类型来看，薪酬预测实际上涉及两种经典的问题范式。

第一个目标是回归任务，即预测一个技术岗位的具体年薪数值。这是一个典型的连续值预测问题。打个比方，给定了岗位类型、工作经验、学历和技能数量等信息之后，我们希望模型能够输出一个具体的薪资数字，比如十四万五千或者十七万八千。这类预测对于求职者来说非常直观——他们可以直接知道在某个岗位上自己大约能拿到多少钱。对于企业的人力资源部门来说，回归预测也可以帮助他们在制定具体薪酬方案时有一个量化的参考基准。

第二个目标是分类任务，即判断一个岗位属于哪一个薪资区间。我们在分

析中把所有岗位按照年薪高低划分为四个档次：低薪区间（十万以下）、中低薪区间（十万到十五万）、中高薪区间（十五万到二十万）和高薪区间（二十万以上）。这个分类结果虽然不像回归那样给出精确数字，但在很多实际场景中反而更加有用。比如，求职者在做职业规划时可能更关心的是自己大致处于哪个薪资层级，而不是精确到个位数的预测值；企业在制定薪酬体系时通常也是以区间为基本单位来设计的。

这两个目标并不是孤立的，而是相辅相成的。回归任务帮助我们理解薪资的精确变化规律，分类任务则帮助我们吧薪资问题简化成更容易理解和决策的层级框架。在实际应用当中，二者可以互相补充、交叉验证。

从应用价值的角度来看，这个项目可以在三个方向上发挥作用。对求职者而言，输入自己的学历背景、工作经验和技能掌握情况，就可以得到一个基于大数据分析的期望薪资参考，这比在招聘网站上逐个浏览职位信息要高效得多。对企业招聘方来说，根据岗位的具体要求和公司所在地区，能够预测出市场化的薪酬范围，从而在招聘竞争中制定具有吸引力的薪资方案。对高校的就业指导部门而言，特征重要性分析所揭示的规律——比如哪些因素对薪资的提升贡献最大——可以为学生的职业规划和技能培养提供数据驱动的建议。

下图展示了四个薪资区间在整体样本中的占比分布。可以直观地看到，中低薪和中高薪区间合计占总样本的百分之八十以上，是技术岗位薪酬的主体区间，而低薪和高薪两个极端区间的样本量相对较少。




图 2-1 薪资区间占比饼图

第三章 数据集说明

任何机器学习项目的质量都在很大程度上取决于数据本身。在这次实践中，我们使用了一个规模可观的数据集，总计包含二十五万条技术岗位的招聘

记录。对于一个课程级别的数据挖掘案例来说，这个样本量已经相当充足，足以支持我们训练出具有较好泛化能力的模型，也能够让分析结论具有一定的统计说服力。

数据集一共包含十三个字段，涵盖了与薪酬相关的多个维度。经过初步的数据质量检查，我们发现所有字段的缺失值均为零，这说明数据的完整度非常高，在数据清洗阶段不需要花费额外的精力去处理缺失值填充的问题。从整体统计来看，数据集中所有岗位的平均年薪约为十四万五千七百一十八元，最低年薪约三万二千元，最高年薪则达到了约三十三万三千元，跨度非常大，反映出不同技术岗位之间确实存在着显著的薪酬分化。

下表列出了数据集中主要的字段及其含义：

序号	字段名称	数据类型	说明
1	job_title（岗位名称）	类别变量	如软件工程师、数据分析师、AI 工程师等
2	experience_years（工作经验年限）	数值变量	从事相关工作的年数
3	education_level（学历水平）	类别变量	如学士、硕士、博士等
4	skills_count（技能数量）	数值变量	掌握的技能种类数量
5	industry（所属行业）	类别变量	如金融、医疗、互联网等
6	company_size（公司规模）	类别变量	如小型、中型、大型企业
7	location（工作地区）	类别变量	所在城市或地区的名称
8	remote_work（远程办公方式）	类别变量	如全职远程、混合办公、现场办公
9	certifications（证书数量）	数值变量	持有的专业认证数量
10	salary（年薪）	连续目标变量	年薪数值，用于回归任务
—	salary_category（薪资区间）	分类标签	由 salary 按阈值划分，用于分类任务

表 3-1 数据集字段说明

为了同时支持回归和分类两种任务，我们在数据预处理阶段进行了针对性的操作。对于回归任务，salary 字段本身就作为连续目标变量直接使用。对于分类任务，我们设定了三个阈值（十万、十五万和二十万）将年薪划分为四个区间。具体的划分结果如下：低薪区间包含两万六千三百三十六条记录，占比约百分之十点五；中低薪区间包含十一万五千九百二十六条记录，占比约百分之四十六点四；中高薪区间包含八万七千四百零五条记录，占比约百分之三十五；高薪区间包含两万零三百三十三条记录，占比约百分之八点一。

从分布来看，中低薪和高薪区间合计占据了总样本的约百分之八十一，是绝对的主体部分。这种不均衡的分布意味着分类模型在训练时可能会更偏向于预测中间两个类别，因此我们在评估模型时不能仅仅看整体的准确率，还需要特别关注每个类别的精确率、召回率和 F1 分数，以确保模型在少数类别（低薪和高薪区间）上的表现也达到可接受的水平。

下面的箱线图可以帮助我们直观地理解数据集中年薪的离散程度和异常值情况：




图 3-1 薪资箱线图

第四章 数据探索与可视化

在正式建立模型之前，我们对数据进行了全面的探索性分析。这个阶段的主要目的是通过可视化和统计描述来理解各个特征与目标变量（年薪）之间的关系，发现数据中存在的模式和趋势，为后续的特征工程和模型选择提供依据。整个探索过程我们生成了十七张不同类型的图表，从多个维度剖析了影响

技术岗位薪资的关键因素。

岗位类型与薪酬

首先来看不同技术岗位之间的平均薪资差异。下面的柱状图对比了数据集中主要岗位类型的平均年薪水平。从中可以非常直观地看到，人工智能工程师和机器学习工程师的薪资处于第一梯队，明显高于其他技术岗位。这反映了当前就业市场对于人工智能相关技能的高度需求以及相应人才供给的相对稀缺。数据分析师和软件工程师处于第二梯队，薪资水平也相当可观，这类岗位的市场需求量大、覆盖面广。而技术支持工程师等偏向运维和服务的岗位薪酬相对偏低，处于第三梯队。




图 4-1 不同岗位平均薪资对比

学历与薪酬的关系

学历是影响薪资的另一个重要因素，而且在很多人的直观认知中，学历和薪酬之间应该存在明显的正向关系。通过数据分析我们验证了这一点——越高的学历层次，对应的平均薪资也越高。从柱状图中可以看到，博士学历的平均薪资显著高于硕士和学士学历，而硕士相对于学士也有明显的溢价。不过值得注意的一个发现是，学历带来的薪资差异并不是均匀分布的——博士学历在进入高薪区间的比例上优势尤其突出，但在中低薪资区间，学历差异带来的影响相对有限。这说明学历的边际价值在薪酬较高的岗位中体现得更为充分。




图 4-2 不同学历平均薪资对比

工作经验与技能数量的影响

工作经验年限和技能数量是两个数值型特征，它们与薪资之间的关系可以通过散点图和趋势线来考察。从散点图的分布来看，虽然数据点的分布存在一定的离散性，但从整体趋势上看，经验年限越长，薪资水平也越高，两者之间存在比较明显的正相关关系。趋势线进一步揭示，在工作经验的前十年左右，薪资的增长速度较快；而在十年之后，增长速度趋于平缓，出现了类似于边际递减的效应。这符合我们对职场的一般认知——职业发展的早期阶段技能增长快、价值提升迅速，而到了中后期增速会自然放缓。




图 4-3 工作经验年限与薪资散点图

技能数量与薪资的关系同样呈现出正相关的趋势。掌握了更多技能的从业者，其薪资水平整体偏高。这一现象的合理解释是，在技术领域，具备复合技能的人才往往可以胜任更复杂的项目、承担更多的角色，因此市场愿意为这种能力的多样性支付更高的报酬。不过也需要注意的是，技能数量与薪资之间的相关性并不是特别强（从相关性热力图中也可以看出），这意味着单纯地堆砌技能数量未必能带来线性的薪资增长，技能的质量、深度和与岗位的匹配度可能更加重要。




图 4-4 技能数量与薪资散点图

多维度综合分析

除了上述几个主要维度之外，我们还分析了公司规模、工作地区和行业类型对薪资的影响。分析结果表明，大型企业（尤其是 Enterprise 级别）提供的平均薪资显著高于中小型企业，这与大公司通常拥有更充足的薪酬预算这一常识是一致的。在工作地区方面，不同国家和城市之间的薪资差异非常明显，美国某些科技中心地区的薪资水平在数据集中表现尤为突出。行业维度上，金融和互联网行业的技术岗位薪酬整体偏高，而教育和公共服务行业的薪资水平则相对较低。远程办公方式对薪资也有一定影响，但这种影响通常与其他因素（如所在地区的生活成本）交织在一起，需要结合具体情况来分析。




图 4-5 相关性热力图

上面的相关性热力图将所有数值变量之间的相关关系用颜色深浅直观地呈现了出来。颜色越深代表相关性越强。从图中可以看出，工作经验年限与薪资之间的相关性相对最高，这与我们前面的散点图分析是一致的。技能数量、证书数量与薪资之间也有一定的正相关性，但程度较经验和岗位类型要弱。此外，我们还使用了主成分分析（PCA）对高维特征进行降维可视化，前两个主成分累计解释了约百分之二十五的变异。PCA 散点图显示不同薪资区间在低维空间中存在明显的重叠，这说明仅靠线性方法难以完美地将不同区间的样本分开，需要使用多种分类模型进行比较和选择。

第五章 回归模型与评估

回归任务是本次实践的第一个核心建模方向，目标是预测技术岗位的具体年薪数值。为了全面比较不同算法的性能差异，我们一共选取了八种具有代表性的回归模型进行训练和评估。这八个模型的选取覆盖了从简单到复杂、从线性到非线性的多种算法类型，为我们提供了一个比较完整的算法性能全景图。

线性回归是最基础的模型，它的优势在于结构简单、可解释性强，能够清晰地体现出每个特征对于目标变量的线性贡献。岭回归在线性回归的基础上引入了 L2 正则化项，用来缓解特征之间可能存在的多重共线性问题，提高了模型的稳定性。KNN 回归是一种基于实例的非参数方法，它根据距离最近的若干个样本的目标值来预测新样本的薪资，适合捕捉局部的数据模式。支持向量回归（SVR）则试图在一定的误差容忍范围内寻找一个最优的拟合函数，对非线性模式有一定的处理能力，但计算成本相对较高。

在树模型方面，决策树回归按照特征的阈值将数据逐层划分，每个叶子节点给出一个预测值，可解释性很强但容易过拟合。随机森林回归通过构建多棵决策树并取平均预测值的方式来降低方差，显著提升了模型的稳定性和泛化能力。梯度提升回归采用逐步迭代的策略，每一轮都在前一轮的残差基础上训练一个新的弱学习器，逐步降低整体误差。XGBoost 回归是目前工业界广泛使用的高效提升树模型，它在梯度提升的基础上加入了正则化和多种优化策略，通常在各类回归任务中都能取得优异的表现。

下面三张对比图分别展示了八个模型在平均绝对误差 (MAE)、均方根误差 (RMSE) 和决定系数 (R^2) 这三个指标上的表现差异：




图 5-1 回归模型 MAE 对比




图 5-2 回归模型 RMSE 对比




图 5-3 回归模型 R² 对比

详细的评估指标汇总如下表所示：

排名	模型	MAE	RMSE	R ²
1	XGBoost 回归	4, 225	5, 295	0. 9798
2	岭回归	5, 436	7, 126	0. 9635
3	线性回归	5, 436	7, 126	0. 9635
4	梯度提升回归	6, 846	8, 711	0. 9454
5	随机森林回归	7, 674	9, 767	0. 9314
6	决策树回归	10, 807	13, 718	0. 8646
7	KNN 回归	13, 586	17, 578	0. 7702
8	SVR	18, 522	23, 929	0. 5741

表 5-1 回归模型评估结果汇总

从评估结果中可以非常清晰地看出，XGBoost 回归在所有三个指标上都遥遥领先。它的 R² 值达到了零点九七九八，这意味着模型能够解释薪资变异中约百分之九十八的部分，预测能力相当强。平均绝对误差仅有四千二百二十五元，对于一个年收入预测问题来说，这个精度已经非常实用。岭回归和线性回归的表现几乎完全相同（R² 均为零点九六三五），这说明在我们的数据集中，

多重共线性并不是一个严重的问题，但正则化也没有带来明显的负面影响。

梯度提升和随机森林作为集成学习方法也取得了不错的成绩（ R^2 均在零点九三以上），但比 XGBoost 略低一些。值得注意的是，单一的决策树模型 R^2 跌到了零点八六四六，远低于集成树模型，这说明单个决策树存在比较严重的过拟合或欠拟合问题，而通过集成多个树的预测，随机森林和提升方法有效地弥补了这一缺陷。KNN 回归和 SVR 在这项任务上的表现相对较差，特别是 SVR 的 R^2 仅有零点五七四一，可能是因为薪资数据的分布和特征空间比较复杂，基于距离或最大间隔的方法难以很好地捕捉其中的规律。

对于表现最优的 XGBoost 模型，我们还进一步分析了它的预测诊断情况。从预测值与真实值的对比散点图来看，大多数样本点紧密地分布在对角线附近，说明模型在整体上的预测偏差很小。残差图也显示残差主要集中分布在零值附近，没有出现系统性的正偏或负偏现象。绝对误差的箱线图进一步确认了误差的集中范围是可控的，绝大多数预测误差都在可以接受的范围内。这些诊断结果表明，XGBoost 模型不仅整体指标优异，而且在各个样本上的预测表现也相对稳定可靠。

第六章 分类模型与评估

分类任务是本次实践的第二个核心建模方向，目标是判断一个技术岗位属于低薪、中低薪、中高薪还是高薪这四个区间中的哪一个。与回归任务输出连续数值不同，分类任务输出的是一个离散的类别标签，这种形式的预测在某些决策场景下更加简洁直观。

我们选取了五种常用的分类模型进行对比实验。Logistic 回归虽然是名字中带有「回归」两个字，但它实际上是分类问题中最经典的方法之一，通过估计样本属于每个类别的概率来进行决策，模型结构简单但性能稳定。KNN 分类与回归类似，基于邻近样本的投票机制来判断新样本的类别归属。决策树分类通过一系列的特征阈值判断将样本路由到不同的叶子节点，整个过程可以直观地可视化为树状结构。随机森林分类通过多棵树的投票来做出最终判断，能够有效降低单棵决策树的方差。梯度提升分类则采用逐步提升的策略，让每一轮的新模型重点关注上一轮被错误分类的样本。

由于这是一个多分类问题且类别分布不完全均衡，我们在评估模型时同时关注了准确率（Accuracy）、精确率（Precision）、召回率（Recall）和 F1 分数这四个指标。准确率反映了整体预测正确的比例，但在类别不均衡的情况下可能会产生误导；精确率和召回率分别从「预测为某类的样本中真正属于该类的比例」和「某类的真实样本中有多少被正确识别」两个角度评估模型；F1 分数则是精确率和召回率的调和平均，能够综合反映模型在各类别上的表现。

下面两张图展示了五个模型在 Accuracy 和 Precision 指标上的对比结果：




图 6-1 分类模型 Accuracy 对比




图 6-2 分类模型 Precision 对比

下面是五个分类模型在四个评估指标上的详细数据：

排名	模型	Accuracy	Precision	Recall	F1-score
1	Logistic 回归	0.9193	0.9193	0.9193	0.9193
2	随机森林分类	0.8446	0.8526	0.8446	0.8399
3	梯度提升分类	0.8366	0.8430	0.8366	0.8307
4	决策树分类	0.8062	0.8073	0.8062	0.8052
5	KNN 分类	0.6977	0.7091	0.6977	0.6896

表 6-1 分类模型评估结果汇总

分类任务的结果中有一个非常值得注意的现象：Logistic 回归以相当大的优势领先于其他所有模型，四个指标均达到了零点九一九三。而随机森林和梯度提升虽然在回归任务中表现良好，但在分类任务中反而输给了简单的 Logistic 回归。这个结果乍一看可能有些令人意外，但从机器学习的角度来看是完全可能的——不同的任务类型和数据特征会使得不同模型的优势得到不同程度的发挥。在这个具体的四分类问题上，Logistic 回归的线性决策边界恰好能够很好地划分四个薪资区间，而树模型可能在某些边界区域的样本上出现了过拟合。

从混淆矩阵的分析中我们可以看到，Logistic 回归对于中低薪区间和中高薪区间的识别效果最好，这两个区间的样本数量庞大且特征模式相对清晰。而在低薪与相邻的中低薪区间之间、以及高薪与相邻的中高薪区间之间，存在一定比例的边界误判情况。这种误判在实际当中是比较合理的——处于区间边界附近的样本本身特征就比较模糊，即便是人工判断也未必能做出准确的分类。决策树和 KNN 在这项任务上表现相对较弱，特别是 KNN 的 F1 分数仅有零点六八九六，这可能是因为四个类别的样本在特征空间中存在较多的交叉和重叠，导致基于距离的方法难以有效区分。

第七章 特征重要性分析

除了模型预测的准确度之外，了解哪些因素对技术岗位的薪资影响最大同样具有重要的实际意义。特征重要性分析可以帮助我们众多的特征中识别出真正起关键作用的变量，这对于求职者的职业规划和企业的人力资源决策都具有参考价值。

在回归任务中，我们利用 XGBoost 模型的内置特征重要性评估机制，对所有输入特征在预测薪资时的贡献度进行了排序。结果显示，工作地区是影响薪资最重要的因素之首。这其实并不难理解——同样的技术岗位在硅谷和在东南亚某个城市的薪资水平可能相差数倍，地区的生活成本和经济发展水平直接决定了薪酬的基本面。紧随其后的是公司规模，特别是 Enterprise 级别的大型企业在薪资水平上具有显著优势。排在第三位的是工作经验年限，这个结果与我们在数据探索阶段看到的正相关趋势完全吻合。另外，岗位类型中的「AI 工程

师」标签和学历中的「博士」标签也在重要性排名中位居前列，进一步印证了人工智能领域的高薪属性和高学历的溢价效应。




图 7-1 回归模型特征重要性 Top20

在分类任务中，我们使用随机森林模型进行特征重要性分析。与回归任务的结果既有相似之处也存在一些差异。最显著的变化是，工作经验年限跃升为分类任务的第一重要特征，超过了工作地区。这说明在判断一个岗位属于哪个薪资区间时，工作经验年限是一个区分度极高的指标。工作地区仍然排名靠前（特别是 India 和 USA 这两个标签），公司规模（Enterprise）和学历（PhD）紧随其后。岗位名称（AI Engineer）在分类任务中也保持了较高的特征重要性，与回归分析形成了一致性的结论。

综合回归和分类两个任务的特征重要性分析，我们可以总结出影响技术岗位薪资的几个共识性关键因素：工作经验年限、工作地区、公司规模和学历水平。这四个因素在两个任务中都展现了稳定的重要性，说明无论我们是从连续值的精确预测还是离散区间的分类判断的角度来看，它们都是决定薪酬水平的核心驱动力。这一发现对于在校学生的职业规划具有直接的指导意义——在选择实习和第一份工作时，除了关注岗位本身的技术方向，也需要认真考虑目标地区和目标公司的规模，因为这些因素在薪资构成中的权重可能比很多人预想的要大得多。

第八章 模型应用与展望

建模和评估只是手段，将模型的预测能力转化为实际价值才是最终的目标。基于我们的回归和分类模型，可以从以下三个方向将研究成果落地应用。

第一个应用方向是企业招聘定薪。在招聘流程中，人力资源部门通常需要

综合考虑岗位需求、市场行情和公司预算来确定一个合理的薪酬范围。利用我们训练好的 XGBoost 回归模型，招聘方只需要输入岗位的具体要求——包括岗位类型、期望的工作经验年限、学历要求、技能需求数量、公司所在的地区和规模等信息，模型就能快速输出一个基于历史数据预测的市场年薪范围。这可以帮助企业在激烈的技术人才竞争中制定出既有竞争力又不超出预算的薪酬方案，同时也减少了招聘人员凭感觉定薪可能带来的偏差。

第二个应用方向是求职者的薪资预测参考。对于正在找工作的技术人员，尤其是缺乏市场经验的应届毕业生，了解自己的合理期望薪资是一件非常困难的事情。通过在线的薪资预测工具，求职者可以输入自己的学历背景、工作经验、掌握的技能数量以及目标岗位类型等信息，系统基于模型预测给出一个期望薪资范围。虽然不能保证预测值与最终实际 offer 金额完全一致，但基于二十五万条真实招聘数据的预测结果，足以作为一个有力的谈判参考依据，帮助求职者在薪资谈判中做到心中有数。

第三个应用方向是高校就业指导。高校的就业指导中心可以利用特征重要性分析的结论，帮助学生更科学地进行职业规划。例如，我们的分析显示工作经验年限是第一或第二重要的特征，这意味着在校期间的实习经历对于未来的薪资水平有着直接影响——就业指导中心可以据此鼓励学生尽早积累实习经验。同样地，工作地区的重要性提示学生在选择就业城市时需要综合考虑生活成本和薪资水平的匹配；学历的重要性则鼓励有意向的学生考虑继续深造。这些基于数据的建议比泛泛的经验之谈更有说服力。

展望未来，这个项目还有不少可以进一步优化的方向。在数据层面，可以考虑引入更多维度的特征，比如具体的编程语言掌握情况、项目经历的质量评价、开源社区的参与度等，这些信息对于技术岗位的薪酬也有重要的解释力，但在当前数据集中并未覆盖。在模型层面，可以尝试深度学习模型（如多层神经网络）以及更复杂的特征交互工程，来进一步提升预测精度。此外，如果能够获取时间序列数据，还可以分析技术岗位薪酬的长期变化趋势，为职业规划提供动态的视角。

第九章 总结与收获

通过这次「技术岗位薪酬预测与薪资区间识别」的小组案例实践，我们完整地体验了一遍数据挖掘的标准工作流程。从最初的问题定义和目标明确，到数据的准备、清洗和预处理，再到探索性数据分析和可视化，然后是多种模型的训练与对比评估，最后是对模型应用场景的思考，六个阶段环环相扣、缺一不可。这种端到端的实践经历对于我们理解数据挖掘方法论的整体框架非常有帮助，也让我们认识到书本上的每一个环节在实际操作中都需要投入相当多的思考和精力。

在多模型对比方面，这次实践给我们留下了深刻的印象。在回归任务中，XGBoost 以远超其他模型的性能夺冠 ($R^2=0.9798$)，充分展示了现代集成学习方法的强大威力；而在分类任务中，简单的 Logistic 回归反而以 $F1=0.9193$ 拔得头筹，这提醒我们「复杂的模型不一定总是更好」——模型的选择必须结合实际数据和任务类型来综合判断。没有一种模型能够在所有场景下都优于其他模型，这是我们通过实践验证的一个重要认知。

在特征工程方面，通过对类别变量进行独热编码、对数值变量进行标准化处理，以及构造衍生变量（经验等级和技能等级），我们深刻体会到了数据预处理质量对最终模型效果的直接影响。尤其是独热编码将类别信息转化为模型可以理解的数值形式这一操作，虽然技术本身并不复杂，但它为后续所有建模工作奠定了基础，没有它就没有后续的所有分析和预测。

从业务洞察的角度来看，特征重要性分析所揭示的规律——工作经验年限、工作地区、公司规模和学历是影响薪资的核心因素——为我们提供了一个量化和系统化的薪资认知框架。这些结论虽然在一定程度上符合我们的直觉，但通过数据和模型来验证直觉、并且量化各个因素的影响权重，这个过程本身非常有价值。它也让我们意识到，在技术驱动的就业市场中，职业规划可以不再仅仅是「跟着感觉走」，而是可以借助数据的力量做出更加理性和前瞻性的决策。

最后，在团队协作方面，这次小组案例实践也锻炼了我们分工合作和沟通协调的能力。从数据预处理到可视化分析、从回归模型到分类模型、从代码编写到报告撰写，每个环节都需要组员之间的密切配合。通过这次实践，我们不仅加深了对数据挖掘技术的理解，也积累了宝贵的团队项目经验。